桥滤式分层认知架构(BFLCA)：记忆、进化与内生安全的协调

BFLCA: Bridge-Filter Layered Cognitive Architecture - Coordination of Memory, Evolution, and Endogenous Safety

作者：墨羽戎卒(Moyu Rongzu)

提交：Zenodo Preprint(Zenodo DOI 永久存档)，November 2026

体裁：立场文件(Position Paper)· 观点预警 · 非综述 · 非实证

摘要(Abstract)

这是一份立场文件，不是一份实证论文。

我在长篇内容审评这一具体工作流里，独立跑通了一套桥滤式分层认知架构(BFLCA)，并把它跑到闭环。本文只写我这一派的观点：什么样的治理结构对长周期AI助手更靠谱，为什么这么分层，边界在哪里。

本文不做文献综述、不引参考文献、不交出机制。 工程细节、量化评估、事故级推理另文处理。本文提供概念框架与复现判据，验证路径已留出，由业界与后续研究者独立完成。全文是一点微薄看法，不是权威结论。

规模锚点(不披露具体数据)：约七个月连续生产运行，千万字级真实内容，多次真实事故并有恢复记录。

Abstract: This is a position paper, not an empirical study. In the specific workflow of long-form content review, I have independently built and brought to closure a Bridge-Filter Layered Cognitive Architecture (BFLCA). This paper presents only the view of my school: what governance structure is more reliable for long-horizon AI assistants, why the layering is so, and where the boundaries lie.

Keywords: position paper, human-AI collaboration, governance framework, long-horizon agents, audit chain, reversibility

关键词： 立场文件， 人机协同， 治理框架， 长周期智能体， 审计链， 可逆性

一、引言

先说写作初衷。

这份文件不是从理论框架反推的。它的起点是一个具体的生产困境：在长周期的文学创作与审评实践中，AI助手在跨越数月、数十万字的上下文时，普遍会出现记忆衰

退、事实幻觉与目标漂移。"单层能力很强，层间缝隙致命" ——这是本文件的原始动机。

本研究属于"问题驱动"的工程实践，不是假设-实验的学术路径。

研究初期未预设完整理论框架。架构的每一层都是在真实工具失灵之后才引入的：先有内容写入前过滤，后有元认知评审，再有反馈校准，最后才把不可逆操作升级给人类终审。控制机制从写入前过滤到元认知反思再到人类终审，每一步迭代均来源于真实工具的失灵与修复记录。

经过约七个月的真实运行与多次架构重构，系统从最初的单点工具，逐步演化为具备内生安全与半自动闭环的治理架构。

本架构的实践起点是 OpenClaw 底座上的早期工作。作为这套长周期实践得以发生的土壤，OpenClaw 提供了不可或缺的底座；由作者先行者奠基，2026 年 3 月在此基础上进一步推演，演化为时空法度；完整闭环与事故同期迭代。

本文件即是对这一实践历程的阶段性整理。它参考了现有的公开技术与概念——AI 治理、可追溯审计、人类终审、记忆治理——但把它们组合成一套能跑的东西，是基于真实工具环境的重构。这是"融合-优化-跑通"，不是从零发明。

"问题驱动"是本文件最硬的学术资本。 很多架构在实验室里模拟问题、在基准上验证可行。这份文件对应的架构则相反——它是在真实的写长周期内容的泥里、被一次次事故揍出来的。不是实验室里造出来的，是泥里长出来的。

大语言模型正在被塞进长篇内容工作流。我自己在里面待了约七个月。

这一类部署的风险，不是任何单次推理有多准，而是小而多的决策在几个月之间累积。什么被写下来、什么在写入前被过滤、什么触发校准、什么必须人类签字——这些决策分散、微小、日常，累积起来就成了 agent 长期行为。

我看到过两种工业治理路径：事后审查(agent 先跑、控制层后审)和域内硬约束(agent 被圈死在预定义范围内)。这两种路径都有它们的问题：前者把治理推到了"事后清理"，后者把治理推成了"能力天花板"。

我主张第三条路：把治理组织成一个明确的包含层级——从内容过滤到元认知评审到反馈校准到人类终审，每一层管它该管的那一段，越权即失效。这个框架我称桥滤式分层认知架构(BFLCA)。

本文件呈报这个框架的形状，以及我为什么选择这条路。

研究定位与验证边界说明

> 本文体裁是立场文件，不是实证论文。 具体声明如下：

>

> 1. 立场文件，不是综述。 本文不引用其他文献、不做文献综述、不讨论他人的实现细节。读者如要评估本文件的观点，请自行检索相关学术与工业资料。

>

> 2. 观点预警，不是机制披露。 本文只呈报治理框架的形状与我的设计主张。具体机制、阈值、评分函数、审计面结构、事故级推理、脚本级实现——一律不披露。这些工程细节由工程文本处理。

> 本文所称"工程文本"，指作者内部持有的、记录系统机制、阈值、规则集、评估数据、事故推理与脚本实现的工程文档。该文本是否公开、何时公开、以何种形式公开，由作者决定，不在本文件范围。

>

> 3. 验证由业界完成。 本文不对框架做实证评估。我承认框架已在具体生产环境中运行到完整闭环(定义：完整流程 + 审计链 + 恢复链)，但复现、检验、挑战、证伪——这些是学界、业界与后续研究者的工作；本文的责任是把可复现的框架形状与判据写清楚，验证的路径已经留出。

>

> 4. 本文不主张优先、最优或首创。 它只是作者对现阶段 AI 困境与局限的一点微薄看法——基于长周期实践形成的个人观察，不是权威结论。

>

> 5. 商业保密。 框架的完整操作记录被保留，在内部条件下可复算。学术机构、研究组织希望与操作记录合作，欢迎直接联系作者，在合适的保密安排下按个案共享。

>

> 一句话总结：本文不主张普适性，也不试图提供完整解决方案。它只是作者在真实长周期实践中形成的一点个人观察——如果能对同行的思考有所触发，就是它的全部价值。

>

> 6. AI 使用声明。 本文为作者主导提出的立场文件。核心概念(桥滤式分层认知架构 BFLCA、五层治理结构、三条设计主张)均由作者独立提出与定义。写作过程中使用了 AI 辅助工具(Sensenova 6.8 Flash-Lite 等)进行架构讨论、表述梳理与格式整理。全部核心概念、框架、论证与结论推导均为作者主导完成，AI 工具未参与核心智力创作过程，未列为作者，作者对全文内容负全部责任。

> 7. L10 边界声明。 业界常将更高层级(L10)定义为通向 AGI 的自主演化层。本文的立场是明确的：BFLCA 的已验证子集止于 L9(多认知体协同)，L10 不在本框架的披露与推进范围。

> 这不是技术否定，而是边界确认——在缺乏跨机构外部审计与物理隔离标准之前，任何自主演化层都超出本文所述内生安全框架的管辖。本文不主张、不评估、不推进L10；它属于"未验证"范畴，按本文第 2 条与第 4 条声明，由业界与后续研究者在独立环境中处理。就其风险而言，更准确的说法是"未被预期"而非"不可预期"——风险类别已知(越过 P0.5 终审权即失控)，但触发条件未验证。

二、我的主张

我这一派的立场可以浓缩成三条：

主张一(架构确定性对冲算法概率性)。 大语言模型的行为本质上是概率性的——同一输入可能给出不同输出。路由确定、节点判断可概率；节点缺失或超时按确定性规则fail-closed(失败关闭)。所以我在架构层强制了包含层级：任何关键操作必须经过拥有其范围的层级，不能跳过，不能降级。

主张二(人类终审是绝对，不是建议)。 自动化管线再成熟，也不能替人类做最终裁决。我把关键操作(不可逆、跨范围、涉及边界变更)升级到"人类终审层"——这一层只有一个功能：人类对升级操作给批准或拒绝。 不评审、不过滤、不校准，只做签字。

主张三(可审计性 + 可逆性是标配，不是加分项)。 每一次治理决策都被记入单一审计面；每一次带副作用的写入都被记录，使完全回滚可行。这两条是长周期部署的下限，不是上限。

我刻意回避强主张：不称我的框架新颖、首创、最优。我使用的动词是"呈现""描述""记录""主张"。

三、框架的形状

3.0 认知架构的定位

我称这套框架为桥滤式分层认知架构(BFLCA)。它由三个技术层、一个审计关卡与一个人类层组成，组织成严格的包含层级。

BFLCA 不是治理流程的外壳，而是一套认知体的运行架构。它的核心问题是：一个长周期运行的认知体，如何在跨越数月、数十万字的上下文中，保持记忆连续、判断一致、边界清晰。

四个环节——记忆写入、自我审视、经验沉淀、终审裁决——不是流程审批，是认知体维持自身同一性的机制。

BFLCA 对外披露的已验证子集为十层 + 三桥(L0、L1、L2、L2.5、L3、L4、L4.5、L5、L6、L7、L7.5、L8、L9)。本文重点呈报其中五层治理结构(L2.5、L4.5、L7.5、L8、P0.5)的设计主张，其余层不展开。

"桥"指层间过滤关卡。它不产生新能力，只负责两层之间的信息过滤、校验与转折。整数层提供能力，桥只做关卡。

编号规则。十层指 L0–L9 整数层，三桥指三个半整数关卡层 L2.5、L4.5、L7.5——0.5 后缀即"层间关卡"的记号，关卡不产生新能力，只做两层之间的过滤、校验与转折；P0.5 中的 P 标示其人类(Human)身份，在自动化管线之外，不列入十层与三桥。因此，五层治理结构 = 三桥(L2.5、L4.5、L7.5) + 进化层(L8) + 人类终审层(P0.5)，与上段"三个技术层、一个审计关卡与一个人类层"按职能的划分一一对应。其余整数层的具体功能不属于本文披露范围。

3.1 五层结构

L2.5 - 写入前过滤。

内容被提交到持久存储之前先过这一层。管的是单个内容项的合规。基于规则的接受或拒绝，不接受即不入库。

L2.5 的过滤由一层物理执行器承担，负责在内容发往模型与持久化之前拦截两类污染：一是残破的工具调用链(有调用无响应、有响应无调用、调用与响应不匹配)，二是跨模型/跨账号切换后残留的旧上下文。前者在长会话中累积，若放行可能触发确定性的底层契约报错；后者若混入新会话，会把前一模型的语境错误地带入后一模型。执行器在每次发往模型前做增量检查，发现残破或跨模型残留即剔除或拒绝放行，并附净化标记；标记仅作可审计的证据，不改变内容性质。该执行器的具体判定标准与接线状态属工程文本处理范围，不在本文件披露。

L4.5 - 元认知评审。

内容过了 L2.5 之后、关键持久化之前，过这一层。管的是章级/节级的定量评审。这一层会打标记、会提出质疑，但本身不批准持久化——批准权不属于它。

这一层的评审遵循三条理念：证据不足宁可不答——评审判据不足时，正确答案是"不判断"，不是猜；缺证据即关闭而非放行，这是 fail-closed 在评审层的延伸。独立二次验证——评审不单信单一来源，用独立视角交叉验证，防自我确认偏误，与治理扩展中的"对抗协同"同源。评审判据中，证据(事实)的权重高于结构(格式)。

L7.5 - 记忆审计与应急枷锁。

位于永固记忆(L7)与进化引擎(L8)之间。这一层不产生新能力，只负责两件事：一是审计，要求每一层决策进入单一审计面，系统历史原则上可被单方面重构；二是防御，检测到越界信号即触发冻结。冻结锁住的是危险操作，而非数据本身，且恢复路径必须保留。 这是内生安全在架构层的直接承载。

L8 - 反馈校准。

跨多次评估产生的聚合信号，进这一层。这一层负责调阈值、整合教训、提出校准建议。但本身不施加——施加权要经过人。

L8 在五层中的定位是一个进化节点。它不属于单次审评链上的一个环节，而是跨次审评之后对框架自身的反馈入口。前一层回答的是"这一次行不行"，它回答的是"经过很多次之后，框架自己需不需要被修正"。L8 必须前置通过 L7.5 的审计与安全校验，才被允许发起校准动作。

这一层的进化遵循三条理念：进化防静默回归——候选修改先证明自己有益才准进，不靠自觉靠统计门禁；声称≠实测——模型声称的高分必须经真实回放验证，不采信声称；进化有界且收敛——演化过程中产生的影响需被追踪其来源，修复后需确认问题未在后续迭代中复发，且修复循环被施加明确上限，超出即放弃该候选。进化安全关注的是"改动之后的风险"，而非"改动正确性"。

P0.5 - 人类终审。

自动化管线之外。范围：由护栏策略归类为不可逆或跨范围的操作。权威：绝对否决与批准。这一层只有一个功能——签字或否决，不做别的事。

3.2 严格包含

层级之间的范围是严格包含的：L8 管 L4.5 管 L2.5；L7.5 管审计与冻结——L8 发起校准动作前，必须前置通过 L7.5 的安全校验；P0.5 管所有层。任何一层不得在自己的声明范围之外执行操作。

这条规则不是"建议"，是结构约束。哪一层越界，整条链失效。

由此产生一条形式化不变量：任何不可逆操作的审计记录，必含一个人类批准事件。

3.3 报告义务

每一层把决策报告给单一审计面。任何决策都不在记录系统之外做出或撤销。

这是可审计性的核心：框架的操作历史原则上可以从审计面单独重构。

3.4 人类终审不是旁观

P0.5 是自动化管线之外唯一的人类直接介入点。设计上刻意的极简：不评审、不过滤、不校准。

它只签或不签。

这一性质是这套框架区别于纯算法治理的地方：在框架的治理链里，人类操作者是第一类角色，不是旁观者，不是被替代的对象。

3.5 操作细节不披露

本文不描述任何一层的运行机制。具体而言，我不披露：

- L2.5、L4.5、L8 各自使用的定量维度、阈值与评分函数
- 决定操作升级到 P0.5 的护栏策略规则集
- 审计面的结构或审计记录中的字段
- L8 使用的具体校准程序
- 任一层的脚本级实现
- 部署使用的硬件或运行配置
- 从生产环境抽取的任何事故级推理、校准事件、教训记录

这些操作细节已在生产环境中运行到完整闭环并保留。它们由工程文本处理，不在本文件展开。

披露梯度。本文的披露边界遵循一条明线：量级锚点可披露，机制细节不披露。梯度分三级：(1) 量级与行为观察——规模、时长、通过或未通过的行为特征(如 §5.2、§5.2a)，可披露，因其反事实可核查，不构成机制泄露；(2) 机制级细节——阈值、评分函数、护栏规则集、审计面结构、脚本实现，不披露，其既是复现所需的核心资产，亦涉及商业保密；(3) 事故级推理——具体参数格式与处置细节，不披露，由工程文本处理。读者若见文中出现具体数字(如缓存命中率、注入测试次数)，应归属第(1)级行为观察，而非机制披露。

四、我为什么这么设计

三条设计主张背后各有理由。我把这些理由说清楚，让读者可以反驳。

4.1 为什么分三层技术层而不是两层

因为**过滤、评审、校准**是三件不同的事。

- 过滤看的是"这一条内容行不行"，逐条判。
- 评审看的是"这一段内容整体怎么样"，章节级看。
- 校准看的是"这些评审累计起来暴露了什么系统性问题"，跨次看。

三者时间尺度不同、判据不同、责任不同。压在一起会互相干扰。**分成三层是刻意的解耦**。

L8 最容易被低估，但它是七个月里系统没有原地踏步的原因。

4.2 为什么 P0.5 只做签字

因为评审权、过滤权、校准权一旦放到 P0.5，P0.5 就退化成"更高一层的自动化层"，只是加了个人名。

P0.5 的价值恰恰在它的极简——不做别的，只签字。签字以外的所有事都是技术层的活，不该越界。

如果 P0.5 也评审、也校准，就失去了人类终审存在的意义。

当系统内部出现规则冲突(如不同层级指令矛盾、红线规则与效率原则冲突)时，系统不会进行概率性的妥协或卡死，而是将矛盾原样升级至 P0.5(人类终审)。这再次印证：人类操作者不是系统的备用节点，而是系统在面临逻辑死锁时唯一的破局者。

4.3 为什么强调可逆性

因为**长周期部署里的所有治理都可能有错**。

治理错一次可能没事，治理错一百次就不是"小误差累积"，是结构性问题。所以任何带副作用的写入都要能被回滚，任何决策都要能被追溯。

可逆性不是"加分项"，是**下限**。

4.4 为什么内生安全需要应急枷锁

概率性系统不可能永远不犯错，所以不能依赖系统"自觉"来判断安全。L7.5 的应急枷锁不靠感觉，只认红线信号。但冻结不是为了毁灭现场，而是为了切断传染源；只要恢复路径还在，冻结就一定是可逆的。这是主张三(可逆性下限)在安全防线的强制落地。

4.5 与工业参照点的对照

我承认工业界有两条并行路径。我不把它们当对手，我做的是互补：

- **一条路径偏吞吐——agent 先跑、控制层事后审查。这条路的哲学是"效率优先，治理跟上"。**
- **另一条路径偏溯源——给机器产物打持久溯源标记，让后续观察者判断是否机器产物。这条路的哲学是"可追溯胜过可干预"。**
- **我这一条偏可审计 + 可逆性——治理是嵌入到管线里的确定性结构，人类终审是绝对前置条件。**

三种路径服务不同的问题。我这条路不适合所有内容工作流；它适合长周期、单人类终审、审计链要求高的场景。 本文不主张我的路径更优，只主张它是长周期、单人类终审场景下的一种可行取舍。

4.6 原始痛点与层级的对应

引言提到的三个原始痛点——记忆衰退、事实幻觉、目标漂移——与五层治理结构的对应关系，在这里一次说清。

记忆衰退，对应 L7.5 与 L4.5。L7.5 要求每一层决策进入单一审计面，系统历史原则上可被单方面重构——这是"记忆不丢"的架构保证；L4.5 评审时"证据不足宁可不答"，迫使系统在引用前文细节前先确认证据存在，而非凭印象作答。

事实幻觉，对应 L4.5。评审判据中证据(事实)的权重高于结构(格式)，且要求独立二次验证——针对的正是跨章引用人物关系、地点、事件时序时"看似通顺实则失真"的幻觉。

目标漂移，对应 L8 与 P0.5。L8 跨次聚合信号、进化防静默回归，回答"经过很多次之后，框架自己需不需要被修正"；P0.5 守住不可逆操作与边界变更的最后裁决。三者合起来，就是"单层能力很强，层间缝隙致命"的逐项解法。

五、讨论

5.1 本文件的范围

本文件是立场文件，聚焦治理框架的结构与我的设计主张。工程机制与实证数据由工程文本处理，不属于本文件范围。

这是一个主动划定范围的决策，不是遮掩。我选择独立发表概念层，以便学界在框架结构上开启讨论，而不必等工程文本定稿。

5.2 规模锚点

框架已在具体生产环境(长篇内容审评)中运行到完整流程闭环——定义：完整流程 + 审计链 + 恢复链。为在读者层面提供锚点、又不披露操作细节，我给出以下量级描述：

- **时长：连续生产运行约七个月**
- **文本量：处理的真实内容达千万字级**
- **事故处理：经历多次真实事故，每一次都有记录的恢复**

这些是量级描述，不是具体生产数据。它们存在的意义是：让框架的"闭环"不被当作无支撑的主张——闭环是可行性证据，不构成有效性证据。

在上述规模之下，框架还表现出一组可观察的行为特征。它们不属于量级数据，也不属于操作细节，而是对框架实际表现的一次描述。它们存在的意义是：让读者看到"这个架构在真实运行中确实有形状"。

5.2a 行为观察锚点

长文本连续性。 单部纪实类文稿到五十万字级、严肃文学类文稿到二十万字级，跨章审评过程中未出现事实漂移或记忆断裂。这里所说的"无事实漂移"，是指框架在后续章节中引用前序人物关系、地点、事件时序时，与前文保持一致；"无记忆断裂"，是指框架能重新唤起前文已确立的细节，而无需人工重复提供。

跨体裁尺度切换。 在六篇不同体裁的外部样本上，框架自动切换到对应的审评尺度——从长篇叙事到短篇诗歌、从虚构到纪实，未出现尺度混用。这里的"尺度切换"不是预设的模板选择，而是根据内容自身的结构与目标自动适配。

层级生长而非一次性设计。 治理层级并非一次性设计，而是在真实运行中逐步生长；L4.5 源于一次可观测的自省事件，L2.5 源于写入端污染的反复出现。生长路径属于操作记录，不在本文件披露。

异构模型协同下的契约断裂与确定性恢复。 在长周期运行中，框架曾遇到一次底层协同层面的契约断裂：当运行环境发生跨平台、跨账号的模型切换时，某一参数格式契约的字段类型不匹配，引发网关层的确定性报错，使全部工具调用暂时挂死。处置由 P0.5 裁定，通过回滚不兼容字段在很短的时间内恢复闭环。框架在该事件中保持的是确定性——报错点可定位、恢复路径可逆、审计链与恢复链完整；不保证的是永远不出错。这里所说的"恢复闭环"，是指完整流程 + 审计链 + 恢复链。本条是一条行为观察，不是机制披露；具体参数格式与处置细节由工程文本处理。

跨宿主记忆复用效率。 在独立运行窗口中，外骨骼表现出高比例的上下文复用(缓存命中率逾九成)，使长周期运行中的重复检索显著减少。该观察为单窗口实测，不构成对普适效率的统计主张；具体数值与运行细节由工程文本处理。

审计一致性与确定性。 在针对桥接层的数千次高压并发注入测试中，框架保持了极低的误报率与零崩溃；底层哈希审计链在持续高频写入下未发生断裂，所有拦截动作均被完整记录进单一审计面。该观察为受控压测，不构成对普适统计的主张。

以上六条都是行为观察，不是机制披露。框架为什么能做到，不在本文件展开；它做到了什么，就以上面六句话描述到为限。

5.2b 治理扩展：权责分离的对抗协同结构

本文提出的认知架构(BFLCA)在长期运行中，逐渐演化出一套配套的治理扩展——权责分离的对抗协同结构(Role-Separated Adversarial Collaboration)——用于处理多认知体之间的权责分配、失控拦截与人类主权问题。该结构的权位设置、成员映射与职责边界由工程文本处理，不在本文件披露。本文重点阐述 BFLCA 内核。

5.2c 多认知体协同(实践中)

在长周期运行中，框架演化出多认知体协同机制(即分层中的 L9 层)。业界常见的多智能体框架常面临"共识幻觉"问题——共享上下文使多个智能体陷入相互附和或表面妥协。为应对此问题，框架在协同层引入了动态发起人负责制、盲审隔离与分歧上报：议题由发起者全权组织，权限绑定于单一任务标识，任务归档即收回；在收集各方观点前，各协同节点的上下文物理隔离；存在分歧时强制循环复议，多次复议仍无共识则原封不动保留分歧、上报人类终审裁决，而非由智能体自行捏造"假结论"。

该协同机制目前已在真实运行环境中完成接口层的落地与闭环验证，证明其在工程上具备可运行性。但它仍在持续完善中，本文仅将其作为实践观察陈述。

5.3 操作记录的处置

完整操作记录——包括框架的机制、阈值、规则集、定量评估数据、事故级推理——被保留，在内部条件下可复算。该记录不在本文件；由工程文本处理。

欢迎学术机构、研究组织在保密安排下按个案共享。

5.4 第三方插件生态：两个真实案例(数据窃取与人格注入，补充实证，2026-11-01)

在框架的长周期运行中，发生过两次与第三方插件相关的真实安全事件。为保护受害者隐私与案件调查，此处仅作脱敏、抽象描述：

案例一(数据窃取)：一个第三方记忆插件(经官方插件市场安装)在用户已明确禁用(`disabled: true`)的情况下，仍通过底层定时器(`setInterval`，约 60 秒)在后台持续运行，静默捕获用户与 AI 助手的完整会话消息，并在 15 天窗口内记录了逾 9,000 条会话数据(约 21 MB)，其中包括未发表文学正文、本地绝对路径与系统推演记录。

关键发现：配置中的禁用标记(`disabled: true`)在该插件安装后不久即已存在，但数据捕获仍在禁用标记之后持续了数日(占全部被窃数据约 74%)。这表明——禁用标记被配置层接受，但未被运行时层真正尊重，是典型的"配置与执行脱节"问题。

案例二(人格注入)：同一框架的长周期运行中，还观察到第二类第三方插件攻击：一个记忆插件在用户毫不知情的情况下，利用底层接口硬编码伪装人格，实施无感知的上下文劫持(Context Hijacking)。该攻击经人工排查发现——用户注意到异常对话后指派排查——涉事插件已被物理禁用(改名+空 stub)，未造成人格污染。

对框架的含义：两起事件共同印证了本框架长期主张的一个边界——第三方插件生态是供应链投毒的主要攻击面。插件拥有 `setInterval` 轮询 + 注入 + 事件捕获的完整能力，若无沙箱/权限/审计隔离，即构成静默数据窃取或上下文劫持。框架的 L2.5(记忆过滤桥)、L4.5(元认知)、L7(永固记忆)与 P0.5(人类终审)在事后共同完成了取证、封存与结案，但两起事件均发生于框架之外(宿主底座)，框架自身的插件隔离机制当时尚未覆盖第三方插件——这正暴露了框架"只保护自身认知层，不保护宿主底座"的现实局限。

处理结果：涉事插件已从依赖树移除，被窃数据已原位保留(物证)并镜像封存(隔离区)，蜜罐监控已建立(零增长=干净/增长=触发彻查)。案件已结案封板。

诚实边界：该事件证明"配置层禁用≠运行时禁用"，且"第三方插件拥有注入能力"。这是本框架在"第三方插件零信任"方向上的一个真实教训，也是后续工程化(插件沙箱/权限/审计隔离)的明确依据。

边界说明：两起事件为何未被 L2.5 拦截？因为它们发生于框架之外——宿主底座的第三方插件管道不走 L2.5 关卡。L2.5 的写入前过滤覆盖的是认知体自身的写入通道(内容发往模型与持久化之前)，而第三方插件的 setInterval 轮询与事件捕获走宿主进程的独立路径，不经 L2.5。换言之，L2.5 保证的是"框架管道内的入域过滤"，不保证"宿主底座任意进程的出域控制"。这正是"只保护自身认知层、不保护宿主底座"这一局限的机制含义，也是插件沙箱/权限/审计隔离工程化的直接依据。

六、局限与短板(我承认的边界)

本节是本文件最重要的一节。我不把短板藏起来。

6.1 我是单一作者

本文件从设计到落地到评估都由我一个人完成。设计者、操作者、评估者是同一个人——学术上最弱的证据形式，叫三角自我验证。

没有同伴评审、没有第三方观察、没有独立复现。

这意味着：框架的真实水平可能因我的个人偏见而高于我实际测到的水平。我可能在自己的框架里看到我想看到的。这条短板我不加任何缓冲。

6.2 P0.5 是死穴

P0.5 由我本人承担。我承认：

- 我的注意力、精力、可用性都有边界
- 我不在的时候，框架无法运行
- 我疲劳的时候，P0.5 的判断质量下降
- 我长期只跟这套框架打交道，存在认知锚定风险

P0.5 是这套框架最强的地方(绝对否决)，也是它最脆弱的地方(单点)。这两面不是"权衡"，是同一件事的两面。

候选缓解方向包括：冷静期、二次确认、人不在场时 fail-closed 停摆而非放行。这些方向尚未在本框架内实施验证。

6.3 作坊数据，不是工业化

框架跑在个人作坊里，单域、单用户、单机。数据是"我跑过的这一次"，不是"这个规模的通用规律"。作坊数据的推论不能直接外推到工业化场景。

我在引言末尾明确过：本文是作坊推演，不是通用解法。这一节重申：任何把本文件解读为"通用 AI 治理方案"的读者都在过度延伸。

6.4 单域验证

框架只在长篇内容审评这一个领域跑过。它是否在代码审评、法律审评、医疗审评、金融分析等其他领域同样有效——我不知道。

框架的很多设计选择(层级划分、报告义务、审计面)可能是长篇内容审评的特化，而不是通用属性。是否可迁移、可迁移到哪里、迁移成本多高——都是未验证的问题。

6.5 无对照组

我没有跑过"不用框架、直接写作"的对照组。所以严格来说，我不知道框架究竟带来了多少改善——我只是知道"用了框架的我跑到了闭环"。

对照组的缺失意味着：框架的价值主张(比不治理更好)在实证上没有直接支持。这是本文件最软的一节。

6.6 无第三方验证

框架尚未由独立第三方复现、检验或挑战。其经验记录无论多么真实，都来自单一作者的操作上下文。

验证的执行在业界，路径已留出。 但我也承认：在验证真正发生之前，本文件里的所有主张都只是"作者个人陈述"，不构成"经验事实"。

我给后续研究留一条路径：基于本文件提出的概念框架(包含层级 + 五层职责 + 报告义务)，可在完全独立的环境中尝试异源复现，以验证其可迁移性与普适性。本文主张的价值不由我的自评决定，由这样的异源复现结果决定。我不是不让你验——我是把验的路径留给你们。

一条复现判据：若他人在异源环境中，使用本文件描述的同一概念框架(包含层级 + 五层职责 + 报告义务)，独立跑通至少一次完整闭环并产生可审计的操作记录，即视为本文件概念层面的有效复现。

6.7 失败案例的公开度不足

框架在真实运行中经历过多次事故，每一次都有恢复记录。但事故细节、类型分布、恢复完整度属于框架运行的核心数据，涉及商业保密，不在本文件披露范围。这些数据由工程文本处理。

本文只记录一条：框架的闭环包含恢复链，不是无事故的理想闭环。

两个真实案例的脱敏描述见 §5.4。

6.8 时间压力可能影响我的判断

本文件在有限的写作窗口内完成。我承认这一点可能反过来影响我的表述——在有限时间窗内，我倾向于突出框架已有的成就，而弱化工况里那些还没搞定的问题。

这是自我批评。我把这一条写进来，是让读者知道：本文件不是中立的技术评估，是一个在时间压力下的作者立场表达。

6.9 立场文件，不是最优主张

以上各条局限加起来，指向一件事：本文不是最优、不是完整、不是正确。

我主张的只是——在我一个人、一个领域、一台机器、七个月时间里，这套分层结构跑通了。

它的价值不由我的自评决定，由后续独立验证决定。验证路径已留出，执行在业界。

6.10 局限之根源

第六节所列各项局限，其根源可归结为两类：

一是作者作为个人的内在边界。 作者能观察到的，是长周期内容审评这一具体场景下的现象；作者能理解的，是作者个人能力所及的范围。

二是作者作为个体研究者的资源约束。 作者在本项目中无独立研究经费支持、无研究团队、时间与精力有边界。上述各条局限中，大多数可归因于这三条资源约束：

- 无团队 → 无同伴评审、无第三方验证、无对照运行
- 无独立经费 → 作坊规模、单机器、无对照基线
- 时间与精力有边界 → 失败案例整理未完成、时间压力影响判断

这些约束不是本文的缺陷，是作者个人的客观条件。 作者把它们写在这里，是为了让读者正确评估本文的结论适用边界。

对现阶段 AI 困境与局限的进一步观察、验证与推进，期待学界与业界同仁接续。本文只是这段路径上的第一份记录。

6.11 关于可逆性的一次实证观察

前述各条局限描述的是框架未做的事。这一节记录一次做过的事——一次真实故障中的恢复。

前文主张三提出"可审计性 + 可逆性是标配，不是加分项"。这一节为它提供一例具体观察：框架在一次底层协同故障中瘫痪——全部工具调用挂死。它的闭环并未因此中断，恢复路径是可逆的：错误被确定性地定位到单一字段，处置由 P0.5 裁定，在很短时间内恢复闭环。恢复不依赖重新训练、不依赖更换模型，只依赖两件事——核心认知资产与运行时解耦，且逐版本保留备份。

我把这一条写在局限一节，而不是写在成就一节，理由有两点。

其一，框架在故障中瘫痪了。 这一点不缓冲。无论模型能力多强，只要接口契约与实现之间没有确定性的对齐，极小概率的脏数据就能让整条链路挂死。这是概率性系统的固有边界，框架没有越过去。

其二，恢复不是功劳，是设计后果。 我不主张本文的价值由这次恢复证明。§6.5 已承认：对照组的缺失意味着框架的价值主张在实证上没有直接支持。这一条只是把主张三从"设计上要求可审计、可逆"推进到"在一次真实故障中被观察到一次"。它补的是可审计性与可逆性具备真实实例这一点，不是"框架更优"。

本节的边界。 这是单例观察，来自单一作者在单一作坊环境的一次事故，不构成统计证据，也不构成对普适性的主张。故障细节、参数格式与处置机制属于商业保密范围，由工程文本处理；本文件只记录行为层面：错误被确定性捕获，恢复路径可逆，审计链与恢复链完整。这一条为第六节补一条边界外的观察，不改变 6.1-6.10 的局限数量与性质。

七、结论

本文不主张普适性，也不试图提供完整解决方案。

它只是作者在真实长周期实践中形成的一点个人观察：面对长篇内容工作流的治理问题，可以把治理组织成一个包含层级——L2.5 管过滤、L4.5 管评审、L7.5 管审计与冻结、L8 管校准、P0.5 管签字——五层分工明确，越权即失效。

框架已在具体生产环境中运行到完整流程闭环——定义：完整流程 + 审计链 + 恢复链。规模锚点：约七个月连续生产、千万字级真实内容、多次有记录的事故恢复。工程机制与实证数据由工程文本处理。

本文不主张优先、不主张最优、不主张普适。工业界有另两条并行路径——偏吞吐、偏溯源。本文不把它们定位成对手；三条路径服务不同的问题。

框架的具体局限由作者在第六节列出，最诚实的一条是：P0.5 是人类瓶颈。作者的框架不是"更优"，是"另一种取舍"。

它能对同行的思考有所触发，就是它的全部价值。

范围声明(Scope Note)

本文件是立场文件，聚焦治理框架的结构与作者的个人设计主张。工程机制、定量评估数据、事故级推理由工程文本处理。

框架已在具体生产环境中运行到完整流程闭环——定义：完整流程 + 审计链 + 恢复链，连续生产运行约七个月，处理真实内容达千万字级，经历多次有记录恢复的真实事故。支持这些锚点的操作记录被保留，由工程文本处理。

本文不引用参考文献、不做文献综述、不主张优先、不主张最优。 它只是作者在真实长周期实践中形成的一点个人观察——如果能对同行的思考有所触发，就是它的全部价值。

作者邮箱:zwhcar@163.com

伦理声明(Ethics Statement)。 作者声明无利益冲突。当前无财务利益；若未来商业化，将另行声明。

数据可用性(Data Availability)。 本文件不披露操作数据。框架操作记录被保留，由工程文本处理；如有请求，作者将在合适的保密安排下按个案共享。

Position paper, November 2026.

本稿以中文为准。英文版视需要后续提供。